

# Mathematic Notes

邵华

2016 年 1 月 28 日

# 目 录

<b>第一章 矩阵计算</b>	<b>2</b>
第 1.1 节 文中符号	2
第 1.2 节 矩阵推导结论	2
第 1.3 节 矩阵微积分	3
1.3.1 符号表示	3
1.3.2 线性乘积的导数	4
1.3.3 二次乘积的导数	4
1.3.4 三次乘积的导数	5
1.3.5 逆矩阵的导数	5
1.3.6 迹的导数	5
1.3.7 行列式的导数	5
1.3.8 雅可比	6
1.3.9 Hessian 矩阵	6
第 1.4 节 二阶锥规划	6
1.4.1 基本形式 [1]	6
1.4.2 半正定问题	7
1.4.3 能够变换为 SOCP 问题的形式	7
<b>第二章 最优化问题与 KKT 条件</b>	<b>8</b>
第 2.1 节 优化问题与对偶函数、对偶问题	8
第 2.2 节 弱对偶性与强对偶性	9
第 2.3 节 互补松性和 KKT 条件	9
<b>第三章 概率和分布相关</b>	<b>11</b>
第 3.1 节 正态分布、Gamma 分布、卡方分布、Nakagami-m 分布	11
3.1.1 Basic: Exponential Distribution	11
3.1.2 Normal Distribution	11
3.1.3 Gamma Distribution	12
3.1.4 Chi-Square Distribution	13
3.1.5 Nakagami-m Distribution	14
第 3.2 节 Moment-Generating Function	14

# 第一章 矩阵计算

## 第 1.1 节 文中符号

- 用大写字母  $\mathbf{A}$  表示矩阵，小写字母  $\mathbf{a}$  表示列向量， $a$  表示实数或者复数标量
- $+, -, *$  分别表示矩阵加，减乘
- $\mathbf{A}^T$  表示  $\mathbf{A}$  的转置
- $\mathbf{A}^H$  表示  $\mathbf{A}$  的共轭转置，如果  $\mathbf{A}$  是实矩阵， $\mathbf{A}^T = \mathbf{A}^H$
- $\mathbf{A}^{-1}, \mathbf{A}^\#, \mathbf{A}^+$  分别表示逆，一般逆和伪逆
- $.*, ./$  表示逐元素的乘法和除法
- $|\mathbf{A}|, \|\mathbf{A}\|_F$  代表行列式和 Frobenius 范数
- $\|\mathbf{a}\|$  代表欧几里得范数
- $|a|$  代表  $a$  的绝对值

## 第 1.2 节 矩阵推导结论

$$\xi_i = \frac{\|\mathbf{HT}\|_{i,i}^2}{[\mathbf{HTT}^H\mathbf{H}^H]_{i,i}} \quad (1.1)$$

将  $\mathbf{HT}$  进行 SVD 分解

$$\mathbf{HT} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^H \quad (1.2)$$

则有：

$$\xi_i = \frac{\|\mathbf{HT}\|_{i,i}^2}{[\mathbf{HTT}^H\mathbf{H}^H]_{i,i}} = \frac{|u_i^H \mathbf{\Lambda} v_i|^2}{|u_i^H \mathbf{\Lambda}^2 v_i|} \quad (1.3)$$

其中， $u_i, v_i$  分别是  $\mathbf{U}^H, \mathbf{V}^H$  的第  $i$  列

Cauchy-Schwarz 不等式:

$$|\langle x, y \rangle|^2 \leq \langle x, x \rangle \cdot \langle y, y \rangle \quad (1.4)$$

Cauchy-Schwarz 积分不等式:

$$\left( \int_a^b f(x)g(x)dx \right)^2 \leq \int_a^b f^2(x)dx \int_a^b g^2(x)dx \quad (1.5)$$

Hölder 不等式, 当  $p, q \geq 1$ , 且  $\frac{1}{p} + \frac{1}{q} = 1$

$$\left| \sum_{i=1}^n a_i b_i \right| \leq \left( \sum_{i=1}^n |a_i|^p \right)^{\frac{1}{p}} \left( \sum_{i=1}^n |b_i|^q \right)^{\frac{1}{q}} \quad (1.6)$$

Minkowski 积分不等式:

$$\left( \int_a^b |f(x)g(x)|^p dx \right)^{\frac{1}{p}} \leq \left( \int_a^b |f(x)|^p dx \right)^{\frac{1}{p}} \left( \int_a^b |g(x)|^p dx \right)^{\frac{1}{p}} \quad (1.7)$$

当  $p=q=2$  时候, Minkowski 积分不等式和 Hölder 不等式退化成 Cauchy 不等式。

Jesen 不等式, 给出了积分的凸函数值和凸函数积分值之间的关系: 若  $f(x)$  是区间  $[a, b]$  的凸函数, 对任意的  $x_1, x_2, x_3, \dots, x_n \in (a, b)$ , 有

$$f\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) \leq \frac{1}{n}[f(x_1) + f(x_2) + \dots + f(x_n)] \quad (1.8)$$

$$\text{Tr}[\mathbf{A}\mathbf{A}^H] = \|\text{vec}(\mathbf{A})\|^2 = \|\text{vec}(\mathbf{A}^H)\|^2 \quad (1.9)$$

$$\sum_i \lambda_i \|\mathbf{A}e_i\|^2 = \text{Tr}\{\mathbf{A}\mathbf{A}^H\} \quad (1.10)$$

## 第 1.3 节 矩阵微积分

### 1.3.1 符号表示

- $d/dx(\mathbf{y})$  是一个向量, 第  $i$  个元素为  $dy(i)/dx$
- $d/d\mathbf{x}(y)$  是一个向量, 第  $i$  个元素为  $dy/dx(i)$
- $d/d\mathbf{x}(\mathbf{y}^T)$  是一个矩阵, 第  $(i, j)$  个元素为  $dy(j)/dx(i)$
- $d/dx(\mathbf{Y})$  是一个矩阵, 第  $(i, j)$  个元素为  $dy(i, j)/dx$

- $d/d\mathbf{X}(\mathbf{y})$  是一个矩阵, 第  $(i, j)$  个元素是  $dy/dx(i, j)$

### 1.3.2 线性乘积的导数

- $d/dx(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A} * d/dx(\mathbf{Y}) * \mathbf{B}$
- $d/dx(\mathbf{A}\mathbf{y}) = \mathbf{A} * d/dx(\mathbf{y})$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{A}) = \mathbf{A}$
- $d/d\mathbf{x}(\mathbf{x}^T) = \mathbf{I}$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{a}) = d/d\mathbf{x}(\mathbf{a}^T\mathbf{x}) = \mathbf{a}$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}\mathbf{b}) = \mathbf{a}\mathbf{b}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}\mathbf{a}) = d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{a}) = \mathbf{a}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{b}) = \mathbf{b}\mathbf{a}^T$
- $d/dx(\mathbf{Y}\mathbf{Z}) = \mathbf{Y} * d/dx(\mathbf{Z}) + d/dx(\mathbf{Y}) * \mathbf{Z}$

### 1.3.3 二次乘积的导数

- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) + \mathbf{D}^T\mathbf{C}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{C}\mathbf{x}) = (\mathbf{C} + \mathbf{C}^T)\mathbf{x}$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{C}\mathbf{x}) = 2\mathbf{C}\mathbf{x}$
- $[\mathbf{C}:\text{symmetric}]d/d\mathbf{x}\mathbf{x}^T\mathbf{x} = 2\mathbf{x}$
- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T(\mathbf{D}\mathbf{x} + \mathbf{e}) + \mathbf{D}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $[\mathbf{C}:\text{symmetric}]d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{b}) = \mathbf{X}(\mathbf{a}\mathbf{b}^T + \mathbf{b}\mathbf{a}^T)$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{a}) = 2\mathbf{X}\mathbf{b}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{b}) = \mathbf{C}^T\mathbf{X}\mathbf{a}\mathbf{b}^T + \mathbf{C}\mathbf{X}\mathbf{b}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{a}) = (\mathbf{C} + \mathbf{C}^T)\mathbf{X}\mathbf{a}\mathbf{a}^T$
- $[\mathbf{C}:\text{Symmetric}]d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{a}) = 2\mathbf{C}\mathbf{X}\mathbf{a}\mathbf{a}^T$
- $d/d\mathbf{X}((\mathbf{X}\mathbf{a} + \mathbf{b})^T)\mathbf{C}(\mathbf{X}\mathbf{a} + \mathbf{b}) = (\mathbf{C} + \mathbf{C}^T)(\mathbf{X}\mathbf{a} + \mathbf{b})\mathbf{a}^T$

## 1.3.4 三次乘积的导数

$$d/d\mathbf{x}(\mathbf{x}^T \mathbf{A} \mathbf{x} \mathbf{x}^T) = (\mathbf{A} + \mathbf{A}^T) \mathbf{x} \mathbf{x}^T + \mathbf{x}^T \mathbf{A} \mathbf{x} \mathbf{I} \quad (1.11)$$

## 1.3.5 逆矩阵的导数

$$d/d\mathbf{x}(\mathbf{Y}^{-1}) = -\mathbf{Y}^{-1} d/d\mathbf{x}(\mathbf{Y}) \mathbf{Y}^{-1} \quad (1.12)$$

## 1.3.6 迹的导数

- $d/d\mathbf{X}(\text{tr}(\mathbf{X})) = \mathbf{I}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X}^k)) = k(\mathbf{X}^{k-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^k)) = \sum_{r=0:k-1} (\mathbf{X}^r \mathbf{A} \mathbf{X}^{k-r-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^{-1} \mathbf{B})) = -(\mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^{-1})) = d/d\mathbf{X}(\text{tr}(\mathbf{X}^{-1} \mathbf{A})) = -\mathbf{X}^{-T} \mathbf{A}^T \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A}^T \mathbf{X} \mathbf{B}^T)) = d/d\mathbf{X}(\text{tr}(\mathbf{B} \mathbf{X}^T \mathbf{A})) = \mathbf{A} \mathbf{B}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X} \mathbf{A}^T)) = d/d\mathbf{X}(\text{tr}(\mathbf{X}^T \mathbf{A})) = d/d\mathbf{X}(\text{tr}(\mathbf{A}^T \mathbf{X})) = d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^T)) = \mathbf{A}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X} \mathbf{B} \mathbf{X}^T)) = \mathbf{A}^T \mathbf{X} \mathbf{B}^T + \mathbf{A} \mathbf{X} \mathbf{B}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X} \mathbf{A} \mathbf{X}^T)) = \mathbf{X}(\mathbf{A} + \mathbf{A}^T)$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})) = \mathbf{X}^T(\mathbf{A} + \mathbf{A}^T)$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^T \mathbf{X})) = (\mathbf{A} + \mathbf{A}^T) \mathbf{X}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X} \mathbf{B} \mathbf{X})) = \mathbf{A}^T \mathbf{X}^T \mathbf{B}^T + \mathbf{B}^T \mathbf{X}^T \mathbf{A}^T$
- [C:symmetric]  $d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} \mathbf{A})) = d/d\mathbf{X}(\text{tr}(\mathbf{A} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1})) = -(\mathbf{C} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}) (\mathbf{A} + \mathbf{A}^T) (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}$
- [B,C:Symmetric]
- $d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{B} \mathbf{X}))) = d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{B} \mathbf{X}) (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1})) = -2(\mathbf{C} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{B} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} + 2\mathbf{B} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}$

## 1.3.7 行列式的导数

- $d/d\mathbf{X}(\det(\mathbf{X})) = d/d\mathbf{X}(\det(\mathbf{X}^T)) = \det(\mathbf{X}) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\det(\mathbf{A} \mathbf{X} \mathbf{B})) = \det(\mathbf{A} \mathbf{X} \mathbf{B}) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\ln(\det(\mathbf{A} \mathbf{X} \mathbf{B}))) = \mathbf{X}^{-T}$

- $d/d\mathbf{X}(\det(\mathbf{X}^k)) = k * \det(\mathbf{X}^k) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\ln(\det(\mathbf{X}^k))) = k\mathbf{X}^{-T}$
- **[Real]**  $d/d\mathbf{X}(\det(\mathbf{X}^T\mathbf{C}\mathbf{X})) = \det(\mathbf{X}^T\mathbf{C}\mathbf{X}) * (\mathbf{C} + \mathbf{C}^T)\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$
- **[C:Real,Symmetric]**  $d/d\mathbf{X}(\det(\mathbf{X}^T\mathbf{C}\mathbf{X})) = 2\det(\mathbf{X}^T\mathbf{C}\mathbf{X}) * \mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$
- **[C:Real,Symmetric]**  $d/d\mathbf{X}(\ln(\det(\mathbf{X}^T\mathbf{C}\mathbf{X}))) = 2\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$

### 1.3.8 雅可比

如果  $\mathbf{y}$  是  $\mathbf{x}$  的函数, 则有  $d\mathbf{y}^T/d\mathbf{x}$  是  $\mathbf{y}$  相对于  $\mathbf{x}$  的雅可比矩阵。  $|d\mathbf{y}^T/d\mathbf{x}|$  称为  $\mathbf{y}$  相对于  $\mathbf{x}$  的雅可比行列式, 它主要用在积分中变换积分变量:

$$\int (f(\mathbf{y})d\mathbf{y}) = \int (f(\mathbf{y}(\mathbf{x}))|d\mathbf{y}^T/d\mathbf{x}|dx) \quad (1.13)$$

### 1.3.9 Hessian 矩阵

如果  $f$  是  $x$  的函数, 则对称矩阵  $d^2f/dx^2 = d/dx^T(df/dx)$  被称为函数  $f(\mathbf{x})$  的 Hessian 矩阵。对于  $df/d\mathbf{x} = 0$  的点, 若 Hessian 矩阵是正定, 负定和不定情况, 分别为最小值, 最大值, 和鞍点。

- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{B})^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{C}\mathbf{D} + \mathbf{D}^T\mathbf{C}^T\mathbf{A}$
- $d^2/dx^2(\mathbf{a}^T\mathbf{x}) = \mathbf{0}$
- $d^2/dx^2(\mathbf{x}^T\mathbf{x}) = 2\mathbf{I}$
- $d^2/dx^2(\mathbf{x}^T\mathbf{C}\mathbf{x}) = \mathbf{C} + \mathbf{C}^T$
- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{D} + \mathbf{D}^T\mathbf{A}$
- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{A}$
- **[C:Symmetric]**  $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{C}\mathbf{A}$

## 第 1.4 节 二阶锥规划

### 1.4.1 基本形式 [1]

$$\begin{aligned} & \text{minimize } f^T(x) \\ & \text{subject to } \|A_i x + b_i\| \leq c_i^T x + d_i, \quad i = 1, 2, \dots, N \end{aligned} \quad (1.14)$$

其中,  $x \in \mathbb{R}^n$  是优化变量, 优化问题的参数为  $f \in \mathbb{R}^n, A_i \in \mathbb{R}^{(n_i-1) \times n}, b_i \in \mathbb{R}^{n_i-1}, c_i \in \mathbb{R}^n, d_i \in \mathbb{R}$ 。范数表示欧几里得范数, 即:  $\|u\| = (u^T u)^{1/2}$ 。约束

$$\|A_i x + b_i\| \leq c_i^T x + d_i \quad (1.15)$$

为维度  $n_i$  的二阶锥约束。因为标准锥, 或者  $k$  维单位二阶凸锥被定义为:

$$\mathcal{C}_k = \left\{ \begin{bmatrix} u \\ t \end{bmatrix} \mid u \in \mathbb{R}^{k-1}, t \in \mathbb{R}, \|u\| \leq t \right\} \quad (1.16)$$

又被称做二次冰锥, 活着洛伦兹锥。由于二阶锥约束的点集是单位二阶锥在仿射映射下的原象:

$$\|A_i x + b_i\| \leq c_i^T x + d_i \iff \begin{bmatrix} A_i \\ c_i^T \end{bmatrix} x + \begin{bmatrix} b_i \\ d_i \end{bmatrix} \in \mathcal{C}_{n_i} \quad (1.17)$$

因此是一个凸约束。故 SOCP 是一个凸优化问题。

## 1.4.2 半正定问题

二阶锥规划可以转化成如下形式的半正定问题:

$$\begin{aligned} & \text{minimize } f^T x \\ & \text{subject to } \begin{bmatrix} (c_i^T x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, N \end{aligned} \quad (1.18)$$

然而, 通过求解半正定规划来求解二次锥优化并不是一个好的办法, 因为内点法对于 SOCP 问题, 比 SDP 问题有更好的收敛速度。

## 1.4.3 能够变换为 SOCP 问题的形式

二次约束的二次规划

范数的和与最大值问题

双曲约束问题

矩阵泛函问题

可表示为二阶锥的函数和集合



## 第二章 最优化问题与 KKT 条件

### 第 2.1 节 优化问题与对偶函数、对偶问题

考虑如下的最优化问题：

$$\begin{aligned} & \text{minimize } f_0(x) \\ & \text{subject to } f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\ & \quad \quad \quad h_i(x) = 0, \quad i = 1, 2, \dots, p \end{aligned} \tag{2.1}$$

其自变量为  $x \in \mathbf{R}^n$ ，设问题的定义域为  $\mathcal{D} = \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$ ，优化问题的最优值为  $p^*$ 。注意，这里并没有假设(2.1)是一个凸优化问题。

问题(2.1)的 Lagrange 函数  $L : \mathbf{R}^n \times \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$  为：

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \tag{2.2}$$

Lagrange 对偶函数  $g$  为  $g : \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$ ，关于 Lagrange 函数关于  $x$  的最小值：

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) \tag{2.3}$$

由于 Lagrange 对偶函数是关于  $(\lambda, v)$  的仿射函数的逐点下确界，所以，即使原问题不是凸的，对偶函数也是凹函数。

于是，有  $\lambda \geq 0, v$ ，下面式子成立：

$$g(\lambda, v) \leq p^* \tag{2.4}$$

即  $g(\lambda, v)$  是原问题最优解的一个下界。

Lagrange 对偶问题：

$$\begin{aligned} & \text{maximize } g(\lambda, v) \\ & \text{subject to } \lambda \geq 0 \end{aligned} \tag{2.5}$$

设 Lagrange 对偶问题具有可行解，即满足  $\lambda \geq 0$  和  $g(\lambda, v) > -\infty$  的一组  $(\lambda, v)$ 。称  $(\lambda^*, v^*)$  为对偶最优解，或者最优 Lagrange 乘子，对应的最优值为  $d^*$ 。根据定义，如下式子成立：

$$d^* \leq p^* \tag{2.6}$$

定义差值  $p^* - d^*$  为原问题的最有对偶间隙。

## 第 2.2 节 弱对偶性与强对偶性

(2.6)称为弱对偶性。若  $p^* = d^*$ ，则称强对偶性成立。

对于一般的情况，强对偶性不成立。但是如果原问题是凸问题，则强对偶性通常（但不总是）成立。强对偶性成立的条件：1. 原问题是凸问题，2. Slater 条件成立：存在一点  $x \in \text{relint } \mathcal{D}$ ，使得下面式子成立了：

$$f_i(x) < 0, i = 1, \dots, m, Ax = b \quad (2.7)$$

满足上面式子的点又被称为是严格可行点，这是因为不等式约束严格成立。

若化的 Slater 条件：若不等式约束函数  $f_i$  中有写函数是仿射函数，则仿射不等式不需要严格成立：

$$f_i(x) \leq 0, i = 1, 2, \dots, k, f_i(x) < 0, i = k + 1, \dots, m, Ax = b \quad (2.8)$$

其中， $f_1, f_2, \dots, f_k$  是仿射的。

注意到当所有的约束条件都是线性等式或者不等式，并且  $\text{dom } f_0$  是开集时，条件(2.8)就是可行性条件。

## 第 2.3 节 互补松性和 KKT 条件

令  $x^*$  和  $(\lambda^*, v^*)$  分别是原问题和对偶问题的最优解，则有：

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &= \inf_x L(x^*, \lambda^*, v^*) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned} \quad (2.9)$$

第一个等式说明最优对偶间隙为零，第二个是对偶函数的定义，第三个不等式根据 Lagrange 函数关于  $x$  求下确界小于等于其在  $x = x^*$  处的值求得。由此可得一个重要的结论：

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0 \quad (2.10)$$

由于每一项都非正，因此有：

$$\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m. \quad (2.11)$$

上面的条件称为互补松弛性。

Karush-Kuhn-Tucker(KKT) 条件：

$$\begin{aligned}
f_x(x^*) &\leq 0, \quad i = 1, \dots, m \\
h_i(x^*) &= 0, \quad i = 1, \dots, m \\
\lambda_i^* &\geq 0, \quad i = 1, \dots, m \\
\lambda_i^* f_i(x^*) &= 0, \quad i = 1, \dots, m
\end{aligned} \tag{2.12}$$

$$\Delta f_0(x^*) + \sum_{i=1}^m \lambda_i^* \Delta f_i(x^*) + \sum_{i=1}^* v_i^* \Delta h_i(x^*) = 0$$

若某个凸优化问题具有可微的目标函数和约束函数，且其满足 Slater 条件，那么 KKT 条件是最优性的充要条件：Slater 条件意味着最优对偶间隙为零，且对偶最优解可以达到，因此  $x$  是原问题最优解，当且仅当存在  $(\lambda, v)$ ，二者满足 KKT 条件。

## 第三章 概率和分布相关

### 第 3.1 节 正态分布、Gamma 分布、卡方分布、Nakagami-m 分布

#### 3.1.1 Basic: Exponential Distributon

PDF:

$$f(x; \lambda) = \lambda e^{-\lambda x} \quad x \geq 0 \quad (3.1)$$

$\lambda$  is the **Rate** parameter, while  $\beta = 1/\lambda$  is the **Scale** parameter.

CDF:

$$F(x; \lambda) = 1 - e^{-\lambda x} \quad x \geq 0 \quad (3.2)$$

$$\mathbb{E}[X] = \frac{1}{\lambda} = \beta, \mathbf{Var}[X] = \frac{1}{\lambda^2}$$

Properties:

- $X_i \sim \text{Exp}(\lambda)$ , then  $\min(X_1, X_2, \dots, X_n) \sim \text{Exp}(n\lambda)$
- $X_i \sim \text{Exp}(\lambda)$ , then  $X_1 + X_2 + \dots + X_k \sim \text{Erlang}(k, \lambda) = \text{Gamma}(k, \lambda^{-1})$  ( $k, \theta$ ) - form

#### 3.1.2 Normal Distribution

Notation:

$$\mathcal{N}(\mu, \sigma^2) \quad (3.3)$$

PDF:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (3.4)$$

CDF:

$$F(x; \mu, \sigma) = \frac{1}{2} [1 + \text{erf}(\frac{(x-\mu)}{\sigma\sqrt{2}})] \quad (3.5)$$

运算:

- $X_1 \sim \mathcal{N}(\mu_1, \sigma_1), X_2 \sim \mathcal{N}(\mu_2, \sigma_2), X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sqrt{\sigma_1^2 + \sigma_2^2})$
- $X \sim \mathcal{N}(\mu, \sigma), \text{then } X^2/\sigma^2 \sim \chi_1(\mu^2/\sigma^2), \chi_1$  为自由度为 1 的卡方分布

- $Z = X_1 X_2$ , 其中  $X_1, X_2$  为标准正态分布, 则  $Z$  为“乘积”正态分布, pdf 为:

$$f_z(z) = \pi^{-1} K_0(|z|) \quad (3.6)$$

其中  $K_0$  为修正第二类 Bessel 函数

微分方程:

$$x^2 \frac{d^2 y}{dx^2} + x \frac{dy}{dx} + (x^2 - \alpha^2)y = 0 \quad (3.7)$$

对于任意的复数  $\alpha$ , 方程的标准解被称为 Bessel 函数。对于正的  $\alpha$  或者整数, 如果方程的解在  $x = 0$  处有届, 则解被称为第一类 Bessel 函数, 记为  $J_\alpha(x)$ ; 如果在  $x = 0$  处为奇异并且多值, 则该解被称为第二类 Bessel 函数, 记为  $Y_\alpha(x)$ .  $H_\alpha^1(x) = J_\alpha(x) + iY_\alpha(x)$ ,  $H_\alpha^2(x) = J_\alpha(x) - iY_\alpha(x)$  为另外两个线性无关的解, 被称为 Hankel 函数。

微分方程:

$$x^2 \frac{d^2 y}{dx^2} + x \frac{dy}{dx} - (x^2 + \alpha^2)y = 0 \quad (3.8)$$

对应的解, 被称为修正的 Bessel 函数, 第一类和第二类分别记录为  $I_\alpha, K_\alpha$

- $Z = \sqrt{X_1^2 + X_2^2}$ , 其中  $X_1, X_2$  为标准正态分布, 则  $Z$  为 Rayleigh 分布
- $Z = X_1 \div X_2$ , 其中  $X_1, X_2$  为标准正态分布, 则  $Z$  为 Cauchy(0,1) 分布
- $Z = X_1^2 + X_2^2 + \dots + X_n^2$ , 其中  $X_i \sim \mathcal{N}(0, 1)$ , 则  $Z$  为  $\chi_n$  自由度为  $n$  的卡方分布
- $X_1, X_2 \dots X_n \sim \mathcal{N}(0, 1), Y_1, Y_2, \dots Y_m \sim \mathcal{N}(0, 1)$ , 则 它们的归一化平方和之比:

$$F = \frac{(X_1^2 + X_2^2 + \dots + X_n^2)/n}{(Y_1^2 + Y_2^2 + \dots + Y_m^2)/m} \sim F_{n,m} \quad (3.9)$$

其中  $F_{n,m}$  为自由度为  $(n, m)$  的 F 分布。

### 3.1.3 Gamma Distribution

Notation: Gamma 分布具有两种表示, 形状—尺度 (shape-scale)

$$X \sim \Gamma(k, \theta) = \text{Gamma}(k, \theta) \quad (3.10)$$

或者形状—率 (shape-rate)

$$X \sim \Gamma(\alpha, \beta) = \text{Gamma}(\alpha, \beta) \quad (3.11)$$

其中  $\alpha = k, \beta = \frac{1}{\theta}$

PDF:

$$f(x; k, \theta) = \frac{x^{k-1} e^{-\frac{x}{\theta}}}{\theta^k \Gamma(k)} \quad (3.12)$$

for  $x > 0, k, \theta > 0$

$$g(x; \alpha, \beta) = \frac{\beta^\alpha x^{\alpha-1} e^{-x\beta}}{\Gamma(\alpha)} \quad (3.13)$$

for  $x > 0, \alpha, \beta > 0$ .

CDF:

$$F(x; k, \theta) = \int_0^x f(u; k, \theta) du = \frac{\gamma(k, \frac{x}{\theta})}{\Gamma(k)} \quad (3.14)$$

其中  $\gamma(.,.)$  为不完全 gamma 函数:  $\gamma(s, x) = \int_0^x t^{s-1} e^{-t} dt$ . 若  $k$  为正整数, 则 gamma 分布为 Erlang 分布.

Summation:

$$\sum_{i=1}^N X_i \sim \text{Gamma}(\sum_{i=1}^N k_i, \theta) \quad (3.15)$$

其中, 所有的  $X_i$  相互独立, 且  $X_i \sim \text{Gamma}(k_i, \theta)$ , 具有相同的尺度参数。

Scaling:

如果  $X \sim \text{Gamma}(k, \theta)$ , 对于  $c > 0$ , 则有  $cX \sim \text{Gamma}(k, c\theta) = \text{Gamma}(\alpha, \beta/c)$ .

事实上, 如果  $X$  为一个指数随机变量, “率” rate 参数为  $\lambda$ , 则  $cX$  为一个率参数 rate 参数为  $\lambda/c$  的随机变量。由于

$$X \sim \text{Exp}(\lambda) = X \sim \text{Gamma}(1, \lambda^{-1}) \quad (k, \theta)\text{-form} \quad (3.16)$$

故有此结论。

### 3.1.4 Chi-Square Distribution

如果  $Z_1, Z_2, Z_3 \dots Z_k$  是独立标准正态随机变量, 则他们的平方和  $Q = \sum_{i=1}^k Z_i^2$  服从卡方分布, 表示为:

$$Q \sim \chi^2(k) \quad \text{or} \quad Q \sim \chi_k^2 \quad (3.17)$$

PDF:

$$f(x; k) = \frac{x^{k/2-1} e^{-x/2}}{2^{k/2} \Gamma(\frac{k}{2})} \quad x > 0; \quad (3.18)$$

$$\Gamma(\frac{1}{2}) = \sqrt{\pi}$$

当  $k = 1$  时, 卡方分布为正态分布的平方;  $k = 2$  时, 为参数为  $1/2$  的指数分布, Rayleigh 分布的平方;  $k = 3$  时, 为参数为  $1$  的 Maxwell 分布的平方  $X \sim \text{Maxwell}(1)$  then  $X^2 \sim \chi^2(2)$ 。

可加性: 独立卡方分布随机变量的和仍旧为卡方分布, 其自由度为所有随机变量自由度之和。

如果  $X_1, X_2 \dots, X_n$  是独立的卡方分布随机变量, 自由度分别为  $k_i$ , 则  $Y = X_1 + X_2 + \dots + X_n$  为自由度为  $\sum_{i=1}^n k_i$  的卡方分布。

### 3.1.5 Nakagami-m Distribution

PDF:

$$f(x; m, \Omega) = \frac{2m^m}{\Gamma(m)\Omega^m} x^{2m-1} \exp\left(-\frac{m}{\Omega} x^2\right) \quad (3.19)$$

其中,  $m, \Omega$  可以表示为:

$$m = \frac{\mathbb{E}^2[X^2]}{\text{Var}[X^2]}, \quad \Omega = \mathbb{E}[X^2] \quad (3.20)$$

Generation:

- 从 Gamma 分布产生, 给定一个  $Y \sim \Gamma(k, \theta)$ , 通过设置  $k = m, \theta = \Omega/m$ , 求取  $Y$  的根号  $X = \sqrt{Y}$ , 则有  $X \sim \text{Nakagami}(m, \Omega)$
- 从 Chi-square 产生, 将卡方分布的自由度  $k$  变为  $2m$ , 同时通过随机变量的尺度变换得到。  $Y \sim \chi(2m), X = \sqrt{\Omega/2m}Y$  服从参数为  $(m, \Omega)$  的 Nakagami 分布。

## 第 3.2 节 Moment-Generating Function

对于一个随机变量  $x$  和对应的概率密度函数  $f(x)$ , 如果存在一个  $h$  使得在  $|t| < h$  时

$$M(t) = \mathbb{E}(e^{tx}) \quad (3.21)$$

$M(t)$  被称为 MGF 函数。

如果随机变量  $X$  和  $Y$  相互独立, 则 MGF 函数满足:

$$\begin{aligned} M_{x+y}(t) &= \mathbb{E}(e^{t(x+y)}) \\ &= \mathbb{E}(e^{tx} e^{ty}) \\ &= \mathbb{E}(e^{tx}) \mathbb{E}(e^{ty}) \\ &= M_x(t) M_y(t) \end{aligned} \quad (3.22)$$

如果  $M(t)$  在 0 点可微, 则在 0 点的  $n$  阶矩可以用 MGF 在 0 点的微分表示:

$$\begin{aligned} M(t) &= \mathbb{E}(e^{tx}) & M(0) &= 1 \\ M'(t) &= \mathbb{E}(xe^{tx}) & M'(0) &= \mathbb{E}(x) \\ M''(t) &= \mathbb{E}(x^2 e^{tx}) & M''(0) &= \mathbb{E}(x^2) \\ M^{(n)}(t) &= \mathbb{E}(x^n e^{tx}) & M^{(n)}(0) &= \mathbb{E}(x^n) \end{aligned} \quad (3.23)$$

对于实分量的随机变量向量  $X$ , MGF 函数可以表示为:

$$M_X(t) = \mathbb{E}(e^{<t, X>}) \quad (3.24)$$

其中  $t$  是一个向量,  $<.,. >$  表示向量点积。

常见分布的 MGF 函数:

Distribution	Moment-generating function
Bernoulli $P(X = 1) = p$	$1 - p + pe^t$
Geometric $(1 - p)^{k-1}p$	$\frac{pe^t}{1 - (1-p)e^t}, \forall t < -\ln(1 - p)$
Binomial $B(n, p)$	$(1 - p + pe^t)^n$
Poisson $\text{Pois}(\lambda)$	$e^{\lambda(e^t - 1)}$
Uniform continuous $U(a, b)$	$\frac{e^{tb} - e^{ta}}{t(b-a)}$
Uniform discrete $U(a, b)$	$\frac{e^{at} - e^{(b+1)t}}{(b-a+1)(1-e^t)}$
Normal $N(\mu, \sigma^2)$	$e^{t\mu + \frac{1}{2}\sigma^2 t^2}$
Multivariate normal $N(\mu, \Sigma)$	$e^{t^T \mu + \frac{1}{2} t^T \Sigma t}$
Chi-square $\chi_k^2$	$(1 - 2k)^{-k/2}$
Gamma $\Gamma(k, \theta)$	$(1 - t\theta)^{-k}$
Exponential $\text{Exp}(\lambda)$	$(1 - t\lambda^{-1})^{-1}, \quad t < \lambda$
Cauchy $(\mu, \theta)$	does not exist
Rayleigh( $\sigma$ )	$1 + \sigma t e^{\sigma^2 t^2 / 2} \sqrt{\frac{\pi}{2}} (erf(\frac{\sigma t}{\sqrt{2}}) + 1)$

表 3.1:



## 参考文献

- [1] Miguel Sousa Lobo, Lieven Vandenberghe, Stephen Boyd, and Hervé Lebret. Applications of second-order cone programming. *Linear Algebra and its Applications*, 284(1–3):193 – 228, 1998. International Linear Algebra Society (ILAS) Symposium on Fast Algorithms for Control, Signals and Image Processing.