

Mathematic Notes

邵华

2016 年 6 月 24 日

目 录

第一章 矩阵计算	3
第 1.1 节 文中符号	3
第 1.2 节 矩阵推导结论	3
第 1.3 节 矩阵微积分	4
1.3.1 符号表示	4
1.3.2 线性乘积的导数	5
1.3.3 二次乘积的导数	5
1.3.4 三次乘积的导数	6
1.3.5 逆矩阵的导数	6
1.3.6 迹的导数	6
1.3.7 行列式的导数	6
1.3.8 雅可比	7
1.3.9 Hessian 矩阵	7
第 1.4 节 二阶锥规划	7
1.4.1 基本形式 [1]	7
1.4.2 半正定问题	8
1.4.3 能够变换为 SOCP 问题的形式	8
第二章 最优化问题与 KKT 条件	9
第 2.1 节 优化问题与对偶函数、对偶问题	9
第 2.2 节 弱对偶性与强对偶性	10
第 2.3 节 互补松性和 KKT 条件	10
第三章 概率和分布相关	12
第 3.1 节 正态分布、Gamma 分布、卡方分布、Nakagami-m 分布	12
3.1.1 Basic: Exponential Distributon	12
3.1.2 Normal Distribution	12
3.1.3 Gamma Distribution	13
3.1.4 Chi-Square Distribution	14
3.1.5 Nakagami-m Distribution	15
第 3.2 节 Moment-Generating Function	15

目 录	2
第四章 博弈论	17
第五章 排队论	18

第一章 矩阵计算

第 1.1 节 文中符号

矩阵计算，通常有分子表示法与分母表示法两种，往往需要根据上下文中的的式子去推导是哪种表示方法。

$$\frac{\partial \mathbf{A}\mathbf{x}}{\partial \mathbf{x}} = \mathbf{A} \quad (1.1)$$

这种表示法，通常为分子表示法；若结果为 \mathbf{A}^T ，则为分母标记法。两种表示法通常结果相差一个转置。

- 用大写字母 \mathbf{A} 表示矩阵，小写字母 \mathbf{a} 表示列向量， a 表示实数或者复数标量
- $+$, $-$, $*$ 分别表示矩阵加，减乘
- \mathbf{A}^T 表示 \mathbf{A} 的转置
- \mathbf{A}^H 表示 \mathbf{A} 的共轭转置，如果 \mathbf{A} 是实矩阵， $\mathbf{A}^T = \mathbf{A}^H$
- \mathbf{A}^{-1} , $\mathbf{A}^\#$, \mathbf{A}^+ 分别表示逆，一般逆和伪逆
- $.*$, $./$ 表示逐元素的乘法和除法
- $|\mathbf{A}|$, $\|\mathbf{A}\|_F$ 代表行列式和 Frobenius 范数
- $\|\mathbf{a}\|$ 代表欧几里得范数
- $|a|$ 代表 a 的绝对值

第 1.2 节 矩阵推导结论

$$\xi_i = \frac{\|\mathbf{HT}\|_{i,i}^2}{[\mathbf{HTT}^H\mathbf{H}^H]_{i,i}} \quad (1.2)$$

将 \mathbf{HT} 进行 SVD 分解

$$\mathbf{HT} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^H \quad (1.3)$$

则有：

$$\xi_i = \frac{\|\mathbf{HT}\|_{i,i}^2}{[\mathbf{HTT}^H\mathbf{H}^H]_{i,i}} = \frac{|u_i^H \mathbf{\Lambda} v_i|^2}{|u_i^H \mathbf{\Lambda}^2 v_i|} \quad (1.4)$$

其中， u_i, v_i 分别是 $\mathbf{U}^H, \mathbf{V}^H$ 的第 i 列

Cauchy-Schwarz 不等式:

$$|\langle x, y \rangle|^2 \leq \langle x, x \rangle \cdot \langle y, y \rangle \quad (1.5)$$

Cauchy-Schwarz 积分不等式:

$$\left(\int_a^b f(x)g(x)dx \right)^2 \leq \int_a^b f^2(x)dx \int_a^b g^2(x)dx \quad (1.6)$$

Hölder 不等式, 当 $p, q \geq 1$, 且 $\frac{1}{p} + \frac{1}{q} = 1$

$$\left| \sum_{i=1}^n a_i b_i \right| \leq \left(\sum_{i=1}^n |a_i|^p \right)^{\frac{1}{p}} \left(\sum_{i=1}^n |b_i|^q \right)^{\frac{1}{q}} \quad (1.7)$$

Minkowski 积分不等式:

$$\left(\int_a^b |f(x)g(x)|^p dx \right)^{\frac{1}{p}} \leq \left(\int_a^b |f(x)|^p dx \right)^{\frac{1}{p}} \left(\int_a^b |g(x)|^p dx \right)^{\frac{1}{p}} \quad (1.8)$$

当 $p=q=2$ 时候, Minkowski 积分不等式和 Hölder 不等式退化成 Cauchy 不等式。

Jesen 不等式, 给出了积分的凸函数值和凸函数积分值之间的关系: 若 $f(x)$ 是区间 $[a, b]$ 的凸函数, 对任意的 $x_1, x_2, x_3, \dots, x_n \in (a, b)$, 有

$$f\left(\frac{x_1 + x_2 + \dots + x_n}{n}\right) \leq \frac{1}{n}[f(x_1) + f(x_2) + \dots + f(x_n)] \quad (1.9)$$

$$\text{Tr}[\mathbf{A}\mathbf{A}^H] = \|\text{vec}(\mathbf{A})\|^2 = \|\text{vec}(\mathbf{A}^H)\|^2 \quad (1.10)$$

$$\sum_i \lambda_i \|\mathbf{A}e_i\|^2 = \text{Tr}\{\mathbf{A}\mathbf{A}^H\} \quad (1.11)$$

第 1.3 节 矩阵微积分

1.3.1 符号表示

- $d/dx(\mathbf{y})$ 是一个向量, 第 i 个元素为 $dy(i)/dx$
- $d/d\mathbf{x}(y)$ 是一个向量, 第 i 个元素为 $dy/dx(i)$
- $d/d\mathbf{x}(\mathbf{y}^T)$ 是一个矩阵, 第 (i, j) 个元素为 $dy(j)/dx(i)$
- $d/dx(\mathbf{Y})$ 是一个矩阵, 第 (i, j) 个元素为 $dy(i, j)/dx$

- $d/d\mathbf{X}(\mathbf{y})$ 是一个矩阵, 第 (i, j) 个元素是 $dy/dx(i, j)$

1.3.2 线性乘积的导数

- $d/dx(\mathbf{A}\mathbf{Y}\mathbf{B}) = \mathbf{A} * d/dx(\mathbf{Y}) * \mathbf{B}$
- $d/dx(\mathbf{A}\mathbf{y}) = \mathbf{A} * d/dx(\mathbf{y})$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{A}) = \mathbf{A}$
- $d/d\mathbf{x}(\mathbf{x}^T) = \mathbf{I}$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{a}) = d/d\mathbf{x}(\mathbf{a}^T\mathbf{x}) = \mathbf{a}$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}\mathbf{b}) = \mathbf{a}\mathbf{b}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}\mathbf{a}) = d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{a}) = \mathbf{a}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{b}) = \mathbf{b}\mathbf{a}^T$
- $d/dx(\mathbf{Y}\mathbf{Z}) = \mathbf{Y} * d/dx(\mathbf{Z}) + d/dx(\mathbf{Y}) * \mathbf{Z}$

1.3.3 二次乘积的导数

- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) + \mathbf{D}^T\mathbf{C}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{C}\mathbf{x}) = (\mathbf{C} + \mathbf{C}^T)\mathbf{x}$
- $d/d\mathbf{x}(\mathbf{x}^T\mathbf{C}\mathbf{x}) = 2\mathbf{C}\mathbf{x}$
- $[\mathbf{C}:\text{symmetric}]d/d\mathbf{x}\mathbf{x}^T\mathbf{x} = 2\mathbf{x}$
- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T(\mathbf{D}\mathbf{x} + \mathbf{e}) + \mathbf{D}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $[\mathbf{C}:\text{symmetric}]d/d\mathbf{x}(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b})$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{b}) = \mathbf{X}(\mathbf{a}\mathbf{b}^T + \mathbf{b}\mathbf{a}^T)$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{X}\mathbf{a}) = 2\mathbf{X}\mathbf{b}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{b}) = \mathbf{C}^T\mathbf{X}\mathbf{a}\mathbf{b}^T + \mathbf{C}\mathbf{X}\mathbf{b}\mathbf{a}^T$
- $d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{a}) = (\mathbf{C} + \mathbf{C}^T)\mathbf{X}\mathbf{a}\mathbf{a}^T$
- $[\mathbf{C}:\text{Symmetric}]d/d\mathbf{X}(\mathbf{a}^T\mathbf{X}^T\mathbf{C}\mathbf{X}\mathbf{a}) = 2\mathbf{C}\mathbf{X}\mathbf{a}\mathbf{a}^T$
- $d/d\mathbf{X}((\mathbf{X}\mathbf{a} + \mathbf{b})^T)\mathbf{C}(\mathbf{X}\mathbf{a} + \mathbf{b}) = (\mathbf{C} + \mathbf{C}^T)(\mathbf{X}\mathbf{a} + \mathbf{b})\mathbf{a}^T$

1.3.4 三次乘积的导数

$$d/d\mathbf{x}(\mathbf{x}^T \mathbf{A} \mathbf{x} \mathbf{x}^T) = (\mathbf{A} + \mathbf{A}^T) \mathbf{x} \mathbf{x}^T + \mathbf{x}^T \mathbf{A} \mathbf{x} \mathbf{I} \quad (1.12)$$

1.3.5 逆矩阵的导数

$$d/d\mathbf{x}(\mathbf{Y}^{-1}) = -\mathbf{Y}^{-1} d/d\mathbf{x}(\mathbf{Y}) \mathbf{Y}^{-1} \quad (1.13)$$

1.3.6 迹的导数

- $d/d\mathbf{X}(\text{tr}(\mathbf{X})) = \mathbf{I}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X}^k)) = k(\mathbf{X}^{k-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^k)) = \sum_{r=0:k-1} (\mathbf{X}^r \mathbf{A} \mathbf{X}^{k-r-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^{-1} \mathbf{B})) = -(\mathbf{X}^{-1} \mathbf{B} \mathbf{A} \mathbf{X}^{-1})^T$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^{-1})) = d/d\mathbf{X}(\text{tr}(\mathbf{X}^{-1} \mathbf{A})) = -\mathbf{X}^{-T} \mathbf{A}^T \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A}^T \mathbf{X} \mathbf{B}^T)) = d/d\mathbf{X}(\text{tr}(\mathbf{B} \mathbf{X}^T \mathbf{A})) = \mathbf{A} \mathbf{B}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X} \mathbf{A}^T)) = d/d\mathbf{X}(\text{tr}(\mathbf{X}^T \mathbf{A})) = d/d\mathbf{X}(\text{tr}(\mathbf{A}^T \mathbf{X})) = d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^T)) = \mathbf{A}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X} \mathbf{B} \mathbf{X}^T)) = \mathbf{A}^T \mathbf{X} \mathbf{B}^T + \mathbf{A} \mathbf{X} \mathbf{B}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X} \mathbf{A} \mathbf{X}^T)) = \mathbf{X}(\mathbf{A} + \mathbf{A}^T)$
- $d/d\mathbf{X}(\text{tr}(\mathbf{X}^T \mathbf{A} \mathbf{X})) = \mathbf{X}^T(\mathbf{A} + \mathbf{A}^T)$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X}^T \mathbf{X})) = (\mathbf{A} + \mathbf{A}^T) \mathbf{X}$
- $d/d\mathbf{X}(\text{tr}(\mathbf{A} \mathbf{X} \mathbf{B} \mathbf{X})) = \mathbf{A}^T \mathbf{X}^T \mathbf{B}^T + \mathbf{B}^T \mathbf{X}^T \mathbf{A}^T$
- [C:symmetric] $d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} \mathbf{A})) = d/d\mathbf{X}(\text{tr}(\mathbf{A} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1})) = -(\mathbf{C} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}) (\mathbf{A} + \mathbf{A}^T) (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}$
- [B,C:Symmetric]
- $d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} (\mathbf{X}^T \mathbf{B} \mathbf{X}))) = d/d\mathbf{X}(\text{tr}((\mathbf{X}^T \mathbf{B} \mathbf{X}) (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1})) = -2(\mathbf{C} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} \mathbf{X}^T \mathbf{B} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1} + 2\mathbf{B} \mathbf{X} (\mathbf{X}^T \mathbf{C} \mathbf{X})^{-1}$

1.3.7 行列式的导数

- $d/d\mathbf{X}(\det(\mathbf{X})) = d/d\mathbf{X}(\det(\mathbf{X}^T)) = \det(\mathbf{X}) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\det(\mathbf{A} \mathbf{X} \mathbf{B})) = \det(\mathbf{A} \mathbf{X} \mathbf{B}) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\ln(\det(\mathbf{A} \mathbf{X} \mathbf{B}))) = \mathbf{X}^{-T}$

- $d/d\mathbf{X}(\det(\mathbf{X}^k)) = k * \det(\mathbf{X}^k) * \mathbf{X}^{-T}$
- $d/d\mathbf{X}(\ln(\det(\mathbf{X}^k))) = k\mathbf{X}^{-T}$
- **[Real]** $d/d\mathbf{X}(\det(\mathbf{X}^T\mathbf{C}\mathbf{X})) = \det(\mathbf{X}^T\mathbf{C}\mathbf{X}) * (\mathbf{C} + \mathbf{C}^T)\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$
- **[C:Real,Symmetric]** $d/d\mathbf{X}(\det(\mathbf{X}^T\mathbf{C}\mathbf{X})) = 2\det(\mathbf{X}^T\mathbf{C}\mathbf{X}) * \mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$
- **[C:Real,Symmetric]** $d/d\mathbf{X}(\ln(\det(\mathbf{X}^T\mathbf{C}\mathbf{X}))) = 2\mathbf{C}\mathbf{X}(\mathbf{X}^T\mathbf{C}\mathbf{X})^{-1}$

1.3.8 雅可比

如果 \mathbf{y} 是 \mathbf{x} 的函数, 则有 $d\mathbf{y}^T/d\mathbf{x}$ 是 \mathbf{y} 相对于 \mathbf{x} 的雅可比矩阵。 $|d\mathbf{y}^T/d\mathbf{x}|$ 称为 \mathbf{y} 相对于 \mathbf{x} 的雅可比行列式, 它主要用在积分中变换积分变量:

$$\int (f(\mathbf{y})d\mathbf{y}) = \int (f(\mathbf{y}(\mathbf{x}))|d\mathbf{y}^T/d\mathbf{x}|dx) \quad (1.14)$$

1.3.9 Hessian 矩阵

如果 f 是 x 的函数, 则对称矩阵 $d^2f/dx^2 = d/dx^T(df/dx)$ 被称为函数 $f(\mathbf{x})$ 的 Hessian 矩阵。对于 $df/d\mathbf{x} = 0$ 的点, 若 Hessian 矩阵是正定, 负定和不定情况, 分别为最小值, 最大值, 和鞍点。

- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{B})^T\mathbf{C}(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{C}\mathbf{D} + \mathbf{D}^T\mathbf{C}^T\mathbf{A}$
- $d^2/dx^2(\mathbf{a}^T\mathbf{x}) = 0$
- $d^2/dx^2(\mathbf{x}^T\mathbf{x}) = 2\mathbf{I}$
- $d^2/dx^2(\mathbf{x}^T\mathbf{C}\mathbf{x}) = \mathbf{C} + \mathbf{C}^T$
- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{D}\mathbf{x} + \mathbf{e}) = \mathbf{A}^T\mathbf{D} + \mathbf{D}^T\mathbf{A}$
- $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{A}$
- **[C:Symmetric]** $d^2/dx^2(\mathbf{A}\mathbf{x} + \mathbf{b})^T\mathbf{C}(\mathbf{A}\mathbf{x} + \mathbf{b}) = 2\mathbf{A}^T\mathbf{C}\mathbf{A}$

第 1.4 节 二阶锥规划

1.4.1 基本形式 [1]

$$\begin{aligned} & \text{minimize } f^T(x) \\ & \text{subject to } \|A_i x + b_i\| \leq c_i^T x + d_i, \quad i = 1, 2, \dots, N \end{aligned} \quad (1.15)$$

其中, $x \in \mathbb{R}^n$ 是优化变量, 优化问题的参数为 $f \in \mathbb{R}^n, A_i \in \mathbb{R}^{(n_i-1) \times n}, b_i \in \mathbb{R}^{n_i-1}, c_i \in \mathbb{R}^n, d_i \in \mathbb{R}$ 。范数表示欧几里得范数, 即: $\|u\| = (u^T u)^{1/2}$ 。约束

$$\|A_i x + b_i\| \leq c_i^T x + d_i \quad (1.16)$$

为维度 n_i 的二阶锥约束。因为标准锥, 或者 k 维单位二阶凸锥被定义为:

$$\mathcal{C}_k = \left\{ \begin{bmatrix} u \\ t \end{bmatrix} \mid u \in \mathbb{R}^{k-1}, t \in \mathbb{R}, \|u\| \leq t \right\} \quad (1.17)$$

又被称做二次冰锥, 活着洛伦兹锥。由于二阶锥约束的点集是单位二阶锥在仿射映射下的原象:

$$\|A_i x + b_i\| \leq c_i^T x + d_i \iff \begin{bmatrix} A_i \\ c_i^T \end{bmatrix} x + \begin{bmatrix} b_i \\ d_i \end{bmatrix} \in \mathcal{C}_{n_i} \quad (1.18)$$

因此是一个凸约束。故 SOCP 是一个凸优化问题。

1.4.2 半正定问题

二阶锥规划可以转化成如下形式的半正定问题:

$$\begin{aligned} & \text{minimize } f^T x \\ & \text{subject to } \begin{bmatrix} (c_i^T x + d_i)I & A_i x + b_i \\ (A_i x + b_i)^T & c_i^T x + d_i \end{bmatrix} \succeq 0, \quad i = 1, \dots, N \end{aligned} \quad (1.19)$$

然而, 通过求解半正定规划来求解二次锥优化并不是一个好的办法, 因为内点法对于 SOCP 问题, 比 SDP 问题有更好的收敛速度。

1.4.3 能够变换为 SOCP 问题的形式

二次约束的二次规划

范数的和与最大值问题

双曲约束问题

矩阵泛函问题

可表示为二阶锥的函数和集合

第二章 最优化问题与 KKT 条件

第 2.1 节 优化问题与对偶函数、对偶问题

考虑如下的最优化问题:

$$\begin{aligned} & \text{minimize } f_0(x) \\ & \text{subject to } f_i(x) \leq 0, \quad i = 1, 2, \dots, m \\ & \quad \quad \quad h_i(x) = 0, \quad i = 1, 2, \dots, p \end{aligned} \tag{2.1}$$

其自变量为 $x \in \mathbf{R}^n$, 设问题的定义域为 $\mathcal{D} = \bigcap_{i=0}^m \text{dom} f_i \cap \bigcap_{i=1}^p \text{dom} h_i$, 优化问题的最优值为 p^* 。注意, 这里并没有假设(2.1)是一个凸优化问题。

问题(2.1)的 Lagrange 函数 $L : \mathbf{R}^n \times \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$ 为:

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \tag{2.2}$$

Lagrange 对偶函数 g 为 $g : \mathbf{R}^m \times \mathbf{R}^p \rightarrow \mathbf{R}$, 关于 **Lagrange 函数** 关于 x 的最小值:

$$g(\lambda, v) = \inf_{x \in \mathcal{D}} L(x, \lambda, v) \tag{2.3}$$

由于 **Lagrange 对偶函数**是关于 (λ, v) 的仿射函数的逐点下确界, 所以, 即使原问题不是凸的, 对偶函数也是凹函数。

于是, 有 $\lambda \geq 0, v$, 下面式子成立:

$$g(\lambda, v) \leq p^* \tag{2.4}$$

即 $g(\lambda, v)$ 是原问题最优解的一个下界。

Lagrange 对偶问题:

$$\begin{aligned} & \text{maximize } g(\lambda, v) \\ & \text{subject to } \lambda \geq 0 \end{aligned} \tag{2.5}$$

设 **Lagrange 对偶问题**具有可行解, 即满足 $\lambda \geq 0$ 和 $g(\lambda, v) > -\infty$ 的一组 (λ, v) 。称 (λ^*, v^*) 为对偶最优解, 或者最优 **Lagrange 乘子**, 对应的最优值为 d^* 。根据定义, 如下式子成立:

$$d^* \leq p^* \tag{2.6}$$

定义差值 $p^* - d^*$ 为原问题的最有对偶间隙。

第 2.2 节 弱对偶性与强对偶性

(2.6)称为弱对偶性。若 $p^* = d^*$ ，则称强对偶性成立。

对于一般的情况，强对偶性不成立。但是如果原问题是凸问题，则强对偶性通常（但不总是）成立。强对偶性成立的条件：1. 原问题是凸问题，2. Slater 条件成立：存在一点 $x \in \text{relint } \mathcal{D}$ ，使得下面式子成立了：

$$f_i(x) < 0, i = 1, \dots, m, Ax = b \quad (2.7)$$

满足上面式子的点又被称为是严格可行点，这是因为不等式约束严格成立。

若化的 Slater 条件：若不等式约束函数 f_i 中有写函数是仿射函数，则仿射不等式不需要严格成立：

$$f_i(x) \leq 0, i = 1, 2, \dots, k, f_i(x) < 0, i = k + 1, \dots, m, Ax = b \quad (2.8)$$

其中， f_1, f_2, \dots, f_k 是仿射的。

注意到当所有的约束条件都是线性等式或者不等式，并且 $\text{dom } f_0$ 是开集时，条件(2.8)就是可行性条件。

第 2.3 节 互补松性和 KKT 条件

令 x^* 和 (λ^*, v^*) 分别是原问题和对偶问题的最优解，则有：

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &= \inf_x L(x^*, \lambda^*, v^*) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned} \quad (2.9)$$

第一个等式说明最优对偶间隙为零，第二个是对偶函数的定义，第三个不等式根据 Lagrange 函数关于 x 求下确界小于等于其在 $x = x^*$ 处的值求得。由此可得一个重要的结论：

$$\sum_{i=1}^m \lambda_i^* f_i(x^*) = 0 \quad (2.10)$$

由于每一项都非正，因此有：

$$\lambda_i^* f_i(x^*) = 0, i = 1, \dots, m. \quad (2.11)$$

上面的条件称为互补松弛性。

Karush-Kuhn-Tucker(KKT) 条件：

$$\begin{aligned}
f_x(x^*) &\leq 0, \quad i = 1, \dots, m \\
h_i(x^*) &= 0, \quad i = 1, \dots, m \\
\lambda_i^* &\geq 0, \quad i = 1, \dots, m \\
\lambda_i^* f_i(x^*) &= 0, \quad i = 1, \dots, m \\
\Delta f_0(x^*) + \sum_{i=1}^m \lambda_i^* \Delta f_i(x^*) + \sum_{i=1}^* v_i^* \Delta h_i(x^*) &= 0
\end{aligned} \tag{2.12}$$

若某个凸优化问题具有可微的目标函数和约束函数，且其满足 Slater 条件，那么 KKT 条件是最优性的充要条件：Slater 条件意味着最优对偶间隙为零，且对偶最优解可以达到，因此 x 是原问题最优解，当且仅当存在 (λ, v) ，二者满足 KKT 条件。

第三章 概率和分布相关

第 3.1 节 正态分布、Gamma 分布、卡方分布、Nakagami-m 分布

3.1.1 Basic: Exponential Distributon

PDF:

$$f(x; \lambda) = \lambda e^{-\lambda x} \quad x \geq 0 \quad (3.1)$$

λ is the **Rate** parameter, while $\beta = 1/\lambda$ is the **Scale** parameter.

CDF:

$$F(x; \lambda) = 1 - e^{-\lambda x} \quad x \geq 0 \quad (3.2)$$

$$\mathbb{E}[X] = \frac{1}{\lambda} = \beta, \mathbf{Var}[X] = \frac{1}{\lambda^2}$$

Properties:

- $X_i \sim \text{Exp}(\lambda)$, then $\min(X_1, X_2, \dots, X_n) \sim \text{Exp}(n\lambda)$
- $X_i \sim \text{Exp}(\lambda)$, then $X_1 + X_2 + \dots + X_k \sim \text{Erlang}(k, \lambda) = \text{Gamma}(k, \lambda^{-1})$ (k, θ) – form

3.1.2 Normal Distribution

Notation:

$$\mathcal{N}(\mu, \sigma^2) \quad (3.3)$$

PDF:

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (3.4)$$

CDF:

$$F(x; \mu, \sigma) = \frac{1}{2} [1 + \text{erf}(\frac{(x-\mu)}{\sigma\sqrt{2}})] \quad (3.5)$$

运算:

- $X_1 \sim \mathcal{N}(\mu_1, \sigma_1), X_2 \sim \mathcal{N}(\mu_2, \sigma_2), X_1 + X_2 \sim \mathcal{N}(\mu_1 + \mu_2, \sqrt{\sigma_1^2 + \sigma_2^2})$
- $X \sim \mathcal{N}(\mu, \sigma), \text{then } X^2/\sigma^2 \sim \chi_1(\mu^2/\sigma^2), \chi_1$ 为自由度为 1 的卡方分布

- $Z = X_1 X_2$, 其中 X_1, X_2 为标准正态分布, 则 Z 为“乘积”正态分布, pdf 为:

$$f_z(z) = \pi^{-1} K_0(|z|) \quad (3.6)$$

其中 K_0 为修正第二类 Bessel 函数

微分方程:

$$x^2 \frac{d^2 y}{dx^2} + x \frac{dy}{dx} + (x^2 - \alpha^2)y = 0 \quad (3.7)$$

对于任意的复数 α , 方程的标准解被称为 Bessel 函数。对于正的 α 或者整数, 如果方程的解在 $x = 0$ 处有届, 则解被称为第一类 Bessel 函数, 记为 $J_\alpha(x)$; 如果在 $x = 0$ 处为奇异并且多值, 则该解被称为第二类 Bessel 函数, 记为 $Y_\alpha(x)$. $H_\alpha^1(x) = J_\alpha(x) + iY_\alpha(x)$, $H_\alpha^2(x) = J_\alpha(x) - iY_\alpha(x)$ 为另外两个线性无关的解, 被称为 Hankel 函数。

微分方程:

$$x^2 \frac{d^2 y}{dx^2} + x \frac{dy}{dx} - (x^2 + \alpha^2)y = 0 \quad (3.8)$$

对应的解, 被称为修正的 Bessel 函数, 第一类和第二类分别记录为 I_α, K_α

- $Z = \sqrt{X_1^2 + X_2^2}$, 其中 X_1, X_2 为标准正态分布, 则 Z 为 Rayleigh 分布
- $Z = X_1 \div X_2$, 其中 X_1, X_2 为标准正态分布, 则 Z 为 Cauchy(0,1) 分布
- $Z = X_1^2 + X_2^2 + \dots + X_n^2$, 其中 $X_i \sim \mathcal{N}(0, 1)$, 则 Z 为 χ_n 自由度为 n 的卡方分布
- $X_1, X_2 \dots X_n \sim \mathcal{N}(0, 1), Y_1, Y_2, \dots Y_m \sim \mathcal{N}(0, 1)$, 则它们的归一化平方和之比:

$$F = \frac{(X_1^2 + X_2^2 + \dots + X_n^2)/n}{(Y_1^2 + Y_2^2 + \dots + Y_m^2)/m} \sim F_{n,m} \quad (3.9)$$

其中 $F_{n,m}$ 为自由度为 (n, m) 的 F 分布。

3.1.3 Gamma Distribution

Notation: Gamma 分布具有两种表示, 形状—尺度 (shape-scale)

$$X \sim \Gamma(k, \theta) = \text{Gamma}(k, \theta) \quad (3.10)$$

或者形状—率 (shape-rate)

$$X \sim \Gamma(\alpha, \beta) = \text{Gamma}(\alpha, \beta) \quad (3.11)$$

其中 $\alpha = k, \beta = \frac{1}{\theta}$

PDF:

$$f(x; k, \theta) = \frac{x^{k-1} e^{-\frac{x}{\theta}}}{\theta^k \Gamma(k)} \quad (3.12)$$

for $x > 0, k, \theta > 0$

$$g(x; \alpha, \beta) = \frac{\beta^\alpha x^{\alpha-1} e^{-x\beta}}{\Gamma(\alpha)} \quad (3.13)$$

for $x > 0, \alpha, \beta > 0$.

CDF:

$$F(x; k, \theta) = \int_0^x f(u; k, \theta) du = \frac{\gamma(k, \frac{x}{\theta})}{\Gamma(k)} \quad (3.14)$$

其中 $\gamma(.,.)$ 为不完全 gamma 函数: $\gamma(s, x) = \int_0^x t^{s-1} e^{-t} dt$. 若 k 为正整数, 则 gamma 分布为 Erlang 分布.

Summation:

$$\sum_{i=1}^N X_i \sim \text{Gamma}(\sum_{i=1}^N k_i, \theta) \quad (3.15)$$

其中, 所有的 X_i 相互独立, 且 $X_i \sim \text{Gamma}(k_i, \theta)$, 具有相同的尺度参数。

Scaling:

如果 $X \sim \text{Gamma}(k, \theta)$, 对于 $c > 0$, 则有 $cX \sim \text{Gamma}(k, c\theta) = \text{Gamma}(\alpha, \beta/c)$.

事实上, 如果 X 为一个指数随机变量, “率” rate 参数为 λ , 则 cX 为一个率参数 rate 参数为 λ/c 的随机变量。由于

$$X \sim \text{Exp}(\lambda) = X \sim \text{Gamma}(1, \lambda^{-1}) \quad (k, \theta)\text{-form} \quad (3.16)$$

故有此结论。

3.1.4 Chi-Square Distribution

如果 $Z_1, Z_2, Z_3 \dots Z_k$ 是独立标准正态随机变量, 则他们的平方和 $Q = \sum_{i=1}^k Z_i^2$ 服从卡方分布, 表示为:

$$Q \sim \chi^2(k) \quad \text{or} \quad Q \sim \chi_k^2 \quad (3.17)$$

PDF:

$$f(x; k) = \frac{x^{k/2-1} e^{-x/2}}{2^{k/2} \Gamma(\frac{k}{2})} \quad x > 0; \quad (3.18)$$

$$\Gamma(\frac{1}{2}) = \sqrt{\pi}$$

当 $k = 1$ 时, 卡方分布为正态分布的平方; $k = 2$ 时, 为参数为 $1/2$ 的指数分布, Rayleigh 分布的平方; $k = 3$ 时, 为参数为 1 的 Maxwell 分布的平方 $X \sim \text{Maxwell}(1)$ then $X^2 \sim \chi^2(2)$ 。

可加性: 独立卡方分布随机变量的和仍旧为卡方分布, 其自由度为所有随机变量自由度之和。

如果 $X_1, X_2 \dots, X_n$ 是独立的卡方分布随机变量, 自由度分别为 k_i , 则 $Y = X_1 + X_2 + \dots + X_n$ 为自由度为 $\sum_{i=1}^n k_i$ 的卡方分布。

3.1.5 Nakagami-m Distribution

PDF:

$$f(x; m, \Omega) = \frac{2m^m}{\Gamma(m)\Omega^m} x^{2m-1} \exp\left(-\frac{m}{\Omega} x^2\right) \quad (3.19)$$

其中, m, Ω 可以表示为:

$$m = \frac{\mathbb{E}^2[X^2]}{\text{Var}[X^2]}, \quad \Omega = \mathbb{E}[X^2] \quad (3.20)$$

Generation:

- 从 Gamma 分布产生, 给定一个 $Y \sim \Gamma(k, \theta)$, 通过设置 $k = m, \theta = \Omega/m$, 求取 Y 的根号 $X = \sqrt{Y}$, 则有 $X \sim \text{Nakagami}(m, \Omega)$
- 从 Chi-square 产生, 将卡方分布的自由度 k 变为 $2m$, 同时通过随机变量的尺度变换得到。 $Y \sim \chi(2m), X = \sqrt{\Omega/2m}Y$ 服从参数为 (m, Ω) 的 Nakagami 分布。

第 3.2 节 Moment-Generating Function

对于一个随机变量 x 和对应的概率密度函数 $f(x)$, 如果存在一个 h 使得在 $|t| < h$ 时

$$M(t) = \mathbb{E}(e^{tx}) \quad (3.21)$$

$M(t)$ 被称为 MGF 函数。

如果随机变量 X 和 Y 相互独立, 则 MGF 函数满足:

$$\begin{aligned} M_{x+y}(t) &= \mathbb{E}(e^{t(x+y)}) \\ &= \mathbb{E}(e^{tx} e^{ty}) \\ &= \mathbb{E}(e^{tx}) \mathbb{E}(e^{ty}) \\ &= M_x(t) M_y(t) \end{aligned} \quad (3.22)$$

如果 $M(t)$ 在 0 点可微, 则在 0 点的 n 阶矩可以用 MGF 在 0 点的微分表示:

$$\begin{aligned} M(t) &= \mathbb{E}(e^{tx}) & M(0) &= 1 \\ M'(t) &= \mathbb{E}(x e^{tx}) & M'(0) &= \mathbb{E}(x) \\ M''(t) &= \mathbb{E}(x^2 e^{tx}) & M''(0) &= \mathbb{E}(x^2) \\ M^{(n)}(t) &= \mathbb{E}(x^n e^{tx}) & M^{(n)}(0) &= \mathbb{E}(x^n) \end{aligned} \quad (3.23)$$

对于实分量的随机变量向量 X , MGF 函数可以表示为:

$$M_X(t) = \mathbb{E}(e^{<t, X>}) \quad (3.24)$$

其中 t 是一个向量, $< \cdot, \cdot >$ 表示向量点积。

常见分布的 MGF 函数:

Distribution	Moment-generating function
Bernoulli $P(X = 1) = p$	$1 - p + pe^t$
Geometric $(1 - p)^{k-1}p$	$\frac{pe^t}{1 - (1-p)e^t}, \forall t < -\ln(1 - p)$
Binomial $B(n, p)$	$(1 - p + pe^t)^n$
Poisson $\text{Pois}(\lambda)$	$e^{\lambda(e^t - 1)}$
Uniform continuous $U(a, b)$	$\frac{e^{tb} - e^{ta}}{t(b-a)}$
Uniform discrete $U(a, b)$	$\frac{e^{at} - e^{(b+1)t}}{(b-a+1)(1-e^t)}$
Normal $N(\mu, \sigma^2)$	$e^{t\mu + \frac{1}{2}\sigma^2 t^2}$
Multivariate normal $N(\mu, \Sigma)$	$e^{t^T \mu + \frac{1}{2} t^T \Sigma t}$
Chi-square χ_k^2	$(1 - 2k)^{-k/2}$
Gamma $\Gamma(k, \theta)$	$(1 - t\theta)^{-k}$
Exponential $\text{Exp}(\lambda)$	$(1 - t\lambda^{-1})^{-1}, \quad t < \lambda$
Cauchy (μ, θ)	does not exist
Rayleigh(σ)	$1 + \sigma t e^{\sigma^2 t^2 / 2} \sqrt{\frac{\pi}{2}} (\text{erf}(\frac{\sigma t}{\sqrt{2}}) + 1)$

表 3.1:

第四章 博弈论

第五章 排队论

参考文献

- [1] Miguel Sousa Lobo, Lieven Vandenberghe, Stephen Boyd, and Hervé Lebret. Applications of second-order cone programming. *Linear Algebra and its Applications*, 284(1–3):193 – 228, 1998. International Linear Algebra Society (ILAS) Symposium on Fast Algorithms for Control, Signals and Image Processing.